MÉTHODES MATHÉMATIQUES

CPES 3 Sciences

De l'estimation à la décision

Intervalles de confiance · Tests d'hypothèses · Régression linéaire

Dario Prandi

CNRS, Université Paris-Saclay, CentraleSupélec

Diapositives pour les chapitres 4 à 7 du polycopié de statistiques · 2026

Plan

Ces diapositives couvrent les chapitres 4 à 7 de la partie « Principes et méthodes statistiques » du polycopié. Les résultats numérotés reprennent la numérotation du polycopié, chapitre par chapitre.

Chapitre 4 **Intervalles de confiance.**
Lois du χ^2, de Student et de Fisher-Snedecor, fonctions pivotales ; intervalles pour la moyenne et la variance d'une loi normale, pour une proportion.

Chapitre 5 **Tests d'hypothèses sur un échantillon.**
Le problème de décision, risques et puissance ; tests de Student sur la moyenne, p-valeur, tests sur la variance et sur une proportion.

Chapitre 6 **Tests du χ^2.**
Théorème de Pearson, test du χ^2, tests d'adéquation.

Chapitre 7 **La régression linéaire.**
Modèle linéaire simple, droite des moindres carrés.

4

chapitre

Intervalles de confiance

- Introduction
- Problématique et définition
- Intervalles de confiance pour les paramètres de la loi normale
- Intervalle de confiance pour une proportion

4.1

Intervalles de confiance

Introduction

Pourquoi un intervalle plutôt qu'une valeur ?

Au chapitre 3, on a estimé θ par une seule valeur $\hat{\theta}_n$.

En général $\hat{\theta}_n$ n'a aucune chance d'être *exactement* égal à θ (même si ESBVM). Par exemple, si sa loi est continue, $\mathbb{P}(\hat{\theta}_n = \theta) = 0$.

On propose donc un ensemble de valeurs vraisemblables pour θ, proches de $\hat{\theta}_n$: une *région de confiance*. Ici $\theta \in \mathbb{R}$, donc la région sera un intervalle, une « fourchette ».

But : un intervalle $\hat{I}_n$, calculé à partir des observations, tel que $\mathbb{P}(\theta \in \hat{I}_n) = 1 - \alpha$, avec α petit.

Méthode :

- écrire une formule contenant les observations et θ, $Y = f(\theta, X_1, \dots, X_n)$, dont la loi est connue et ne dépend pas de θ ;
- fixer $\alpha \in (0, 1)$ et trouver un intervalle $I(\alpha) \subset \mathbb{R}$ tel que $\mathbb{P}(Y \in I(\alpha)) = 1 - \alpha$;
- *isoler* θ : trouver $\hat{I}_n$ tel que $\theta \in \hat{I}_n$ si et seulement si $Y \in I(\alpha)$.

Les quantiles

On cherchera $I(\alpha)$ de la forme $[q_\alpha, +\infty[$, $]-\infty, q_{1-\alpha}]$, ou $[q_{\alpha/2}, q_{1-\alpha/2}]$.

La définition suivante sera donc essentielle :

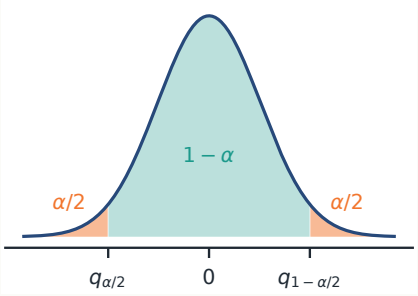
Définition 1.2 (quantile)

Pour une variable aléatoire continue X et $\alpha \in [0,1]$, le quantile d'ordre α de la loi de X est

$$q_\alpha \in \mathbb{R} \text{ tel que } \mathbb{P}(X \leq q_\alpha) = \alpha.$$

Notation dans ces diapositives.

- q_p est le quantile d'ordre p de $\mathcal{N}(0,1)$
- $q_{\mathrm{St}(k),p}$ celui de $\mathrm{St}(k)$
- $q_{\chi^2(k),p}$ celui de $\chi^2(k)$
- $q_{F(n,m),p}$ celui de $F(n,m)$



Loi $\mathcal{N}(0,1)$: entre les quantiles d'ordre $\alpha/2$ et $1-\alpha/2$ se trouve une probabilité $1-\alpha$.

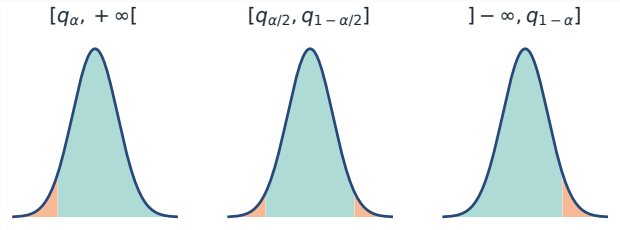
Le point de vue graphique

Exemple.
Considérons $X_1, \dots, X_n \sim \mathcal{N}(m, \sigma^2)$ et cherchons un intervalle de confiance $\hat{I}_n$ pour m.
Nous avons,

$$\sqrt{n}\,(\bar{X}_n - m)/\sigma \sim \mathcal{N}(0, 1).$$

Donc, pour $\alpha = 5\%$, $\mathbb{P}\big(q_{,025} < \sqrt{n}\,(\bar{X}_n - m)/\sigma < q_{,975}\big) = 95\%$.
Il reste à isoler m :

$$\hat{I}_n = \Big[\bar{X}_n - \frac{\sigma}{\sqrt{n}}\,q_{,975},\ \bar{X}_n - \frac{\sigma}{\sqrt{n}}\,q_{,025}\Big]$$



En vert, la probabilité 1 - α conservée ; en orange, le risque α.

Trois types d'intervalles :

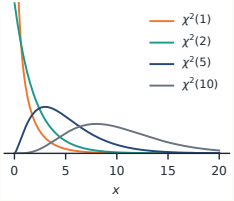
- $[q_\alpha, +\infty[$: *unilatéral à gauche* ;
- $[q_{\alpha/2}, q_{1-\alpha/2}]$: *bilatéral*, à risques symétriques ;
- $]-\infty, q_{1-\alpha}]$: *unilatéral à droite*.

Trois lois déduites de la loi normale

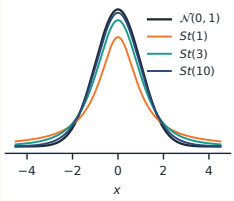
Dans la suite, on aura besoin des lois suivantes.

Définition 1.1 (lois du χ^2, de Student, de Fisher-Snedecor)

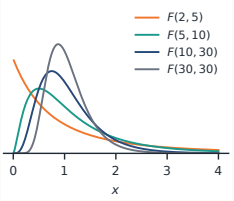
- $X_1, \dots, X_n$ iid de loi $\mathcal{N}(0,1)$: $\sum_{i=1}^n X_i^2$ suit la loi du chi-deux à n degrés de liberté, notée $\chi^2(n)$.
- $U \sim \mathcal{N}(0,1)$ et $X \sim \chi^2(k)$ indépendantes : $\dfrac{U}{\sqrt{X/k}}$ suit la loi de Student à k degrés de liberté, notée $\mathrm{St}(k)$.
- $X \sim \chi^2(n)$ et $Y \sim \chi^2(m)$ indépendantes : $\dfrac{X/n}{Y/m}$ suit la loi de Fisher-Snedecor de paramètres n et m, notée $F(n,m)$.



$\chi^2(n)$: positive, asymétrique, d'espérance n.



$\mathrm{St}(k)$: symétrique, queues plus lourdes que $\mathcal{N}(0,1)$, qu'elle rejoint quand $k \to \infty$.



$F(n,m)$: positive, asymétrique ; si $X \sim F(n,m)$ alors $1/X \sim F(m,n)$.

Théorème 1.1 (théorème de Fisher)

$X_1, \dots, X_n$ iid de loi $\mathcal{N}(m, \sigma^2)$; moyenne et variance empiriques

$$\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad S_n^2 = \frac{1}{n}\sum_{i=1}^{n} \left(X_i - \bar{X}_n\right)^2.$$

Alors, $\bar{X}_n$ et S_n^2 sont indépendantes. De plus,

$$\sum_{i=1}^{n} X_i \sim \mathcal{N}(nm,\, n\sigma^2), \qquad \bar{X}_n \sim \mathcal{N}\left(m,\, \sigma^2/n\right)$$

$$\frac{1}{\sigma^2}\sum_{i=1}^{n}(X_i - m)^2 \sim \chi^2(n), \qquad \frac{1}{\sigma^2}\sum_{i=1}^{n}\left(X_i - \bar{X}_n\right)^2 = \frac{nS_n^2}{\sigma^2} \sim \chi^2(n-1)$$

$$\sqrt{n-1}\,\frac{\bar{X}_n - m}{S_n} \sim \mathrm{St}(n-1)$$

- Idée clef : les v.a. des deux dernières lignes dépendent de m et σ, mais pas leurs *lois*.
- Remplacer m par $\bar{X}_n$ « coûte » un degré de liberté.

Ces variables aléatoires de loi connue, indépendante des paramètres, sont dites fonctions pivotales.

Lire les tables

Deux types de lois, donc deux types de tables (annexe C du polycopié).

Lois symétriques : $\mathcal{N}(0,1)$, $\mathrm{St}(n)$

La table est indexée par le risque *bilatéral* α et donne le quantile d'ordre $1-\alpha/2$: la valeur q telle que $\mathbb{P}(|X|>q)=\alpha$.

Pour lire $q_{,95}$, chercher la colonne $\alpha = 0{,}10$. Pour $q_{,975}$, la colonne $\alpha = 0{,}05$: on trouve 1,96.

Lois non symétriques : $\chi^2(n)$, $F(n_1,n_2)$

La table est indexée par le risque *unilatéral* α et donne le quantile d'ordre $1-\alpha$: la valeur q telle que $\mathbb{P}(X>q)=\alpha$.

Pour lire $q_{\chi^2(19),,975}$, chercher la colonne $\alpha = 0{,}025$: on trouve 32,85. Pour la loi de Fisher, le polycopié ne fournit qu'une table pour $\alpha = 5\%$ (et une pour 1%).

- Pour une loi symétrique, $q_\alpha = -q_{1-\alpha}$: il suffit de connaître les quantiles d'ordre supérieur à 1/2.
- Avec un logiciel, `qnorm`, `qt`, `qchisq`, `qf` donnent directement le quantile d'ordre p demandé.

Quelle que soit la table, vérifier d'abord *quelle* probabilité elle indexe : $\mathbb{P}(|X|>q)$ ou $\mathbb{P}(X>q)$.

4.2

Intervalles de confiance

Problématique et définition

Définition 2.1 (intervalle de confiance)

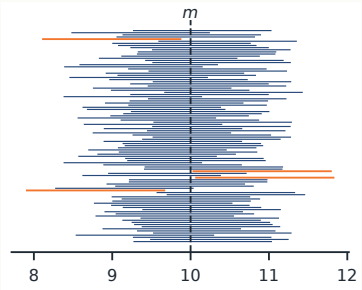
Un intervalle de confiance de seuil (ou *niveau de signification*) $\alpha \in [0, 1]$ pour un paramètre θ est un intervalle *aléatoire* I tel que $\mathbb{P}(\theta \in I) = 1 - \alpha$.

α est la probabilité que I ne contienne pas θ, donc la probabilité de se tromper en affirmant $\theta \in I$.
Valeurs usuelles pour α : 10%, 5%, 1%.

Attention aux abus de langage. Dans $\mathbb{P}(\theta \in I)$, θ est inconnu mais *non aléatoire* ; ce sont les bornes Z_1, Z_2 de $I = [Z_1, Z_2]$ qui le sont. Pour une expérience donnée, elles prennent des valeurs z_1, z_2, par exemple $z_1 = 440$ et $z_2 = 460$ pour le paramètre λ de l'exemple des particules (TD, exercice 15).

- Correct : « λ a 95 % de chances d'être compris entre Z_1 et Z_2 ».
- Incorrect : « λ a 95 % de chances d'être compris entre 440 et 460 ». Plus rien n'est aléatoire : λ est, ou n'est pas, dans $[440, 460]$.

On dira plutôt : « on a une confiance de 95 % dans le fait que λ soit compris entre 440 et 460 ».



4 intervalles sur 100 ne contiennent pas m

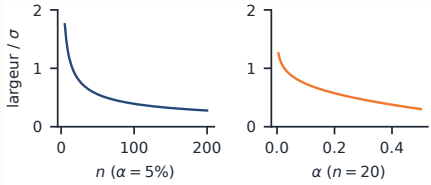
Comment construire un intervalle de confiance ?

Il est naturel de chercher $I = [\hat{\theta}_n - \varepsilon,\ \hat{\theta}_n + \varepsilon]$, centré sur un bon estimateur, avec ε tel que $\mathbb{P}\left(\left|\hat{\theta}_n - \theta\right| \leq \varepsilon\right) = 1 - \alpha$. Mais α est fixé à l'avance et ε ne doit pas dépendre de θ : cela n'est possible que si la *loi* de $\hat{\theta}_n - \theta$ ne dépend pas de θ, ce qui n'est pas toujours le cas.

La méthode générale : chercher une fonction pivotale, fonction de $X_1, \ldots, X_n$ et de θ dont la loi ne dépend pas de θ. C'est elle qui impose la forme de l'intervalle.

Programme du chapitre

- $\mathcal{N}(m, \sigma^2)$: IC pour m (σ connue, puis inconnue), IC pour σ^2 ;
- $\mathcal{B}(p)$: IC asymptotique pour p.



Largeur de l'IC pour m, en unités de σ : elle décroît comme $1/\sqrt{n}$ et croît quand α diminue.

- L'intervalle dépend de l'estimation $\hat{\theta}_n$ et de α : plus α est petit, plus la confiance est grande, plus l'intervalle est large.
- Quand n grandit, $\mathrm{Var}(\hat{\theta}_n)$ diminue et l'intervalle se resserre : sa largeur mesure la précision de l'estimateur.

Intervalles de confiance

4.3 Intervalles de confiance pour les paramètres de la loi normale

IC pour l'espérance, variance connue

$X_1, \dots, X_n$ iid de loi $\mathcal{N}(m, \sigma^2)$, σ connue. L'ESBVM de m est $\bar{X}_n$, et par le théorème de Fisher

$$\bar{X}_n \sim \mathcal{N}\Big(m, \frac{\sigma^2}{n}\Big), \qquad \text{donc} \qquad U = \sqrt{n}\,\frac{\bar{X}_n - m}{\sigma} \sim \mathcal{N}(0,1).$$

En prenant des risques symétriques,

$$1 - \alpha = \mathbb{P}\big(q_{\alpha/2} \le U \le q_{1-\alpha/2}\big) = \mathbb{P}\Big(\bar{X}_n - \tfrac{\sigma}{\sqrt{n}}\, q_{1-\alpha/2} \le m \le \bar{X}_n - \tfrac{\sigma}{\sqrt{n}}\, q_{\alpha/2}\Big).$$

Proposition 3.1
La loi normale étant symétrique, $q_{\alpha/2} = -q_{1-\alpha/2}$.

Par exemple $q_{,975} = 1{,}96$ pour $\alpha = 5\%$, et $q_{,95} = 1{,}645$ pour $\alpha = 10\%$.

Proposition 3.2 (IC pour m, σ connue)
Un intervalle de confiance de seuil α pour le paramètre m de la loi $\mathcal{N}(m, \sigma^2)$ est

$$\Big[\bar{X}_n - \frac{\sigma}{\sqrt{n}}\, q_{1-\alpha/2},\ \bar{X}_n + \frac{\sigma}{\sqrt{n}}\, q_{1-\alpha/2}\Big], \qquad q_{1-\alpha/2} \text{ quantile d'ordre } 1 - \tfrac{\alpha}{2} \text{ de } \mathcal{N}(0,1).$$

Cet intervalle n'est utilisable que si l'on connaît σ. En pratique, on ne connaît jamais les vraies valeurs des paramètres.

IC pour l'espérance, variance inconnue

Idée naturelle : remplacer σ par son estimateur S'_n.

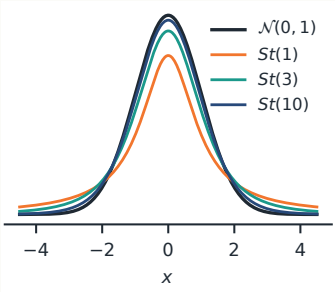
Mais $\sqrt{n}\,(\bar{X}_n - m)/S'_n$ n'est *pas* de loi $\mathcal{N}(0,1)$: l'intervalle obtenu en recopiant la proposition 3.2 n'est pas de seuil α.

Le théorème de Fisher fournit la bonne fonction pivotale :

$$Y = \sqrt{n}\,\frac{\bar{X}_n - m}{S'_n} = \sqrt{n-1}\,\frac{\bar{X}_n - m}{S_n} \sim \mathrm{St}(n-1),$$

et la loi de Student est symétrique :

$$\mathbb{P}\big(-q_{\mathrm{St}(n-1),\,1-\alpha/2} \le Y \le q_{\mathrm{St}(n-1),\,1-\alpha/2}\big) = 1-\alpha.$$



Queues plus lourdes : $q_{\mathrm{St}(k),\,1-\alpha/2} > q_{1-\alpha/2}$. Estimer σ se paie par un intervalle plus large.

Proposition 3.3 (IC pour m, σ inconnue)

Un intervalle de confiance de seuil α pour m est

$$\Big[\bar{X}_n - \frac{S'_n}{\sqrt{n}}\,q_{\mathrm{St}(n-1),\,1-\alpha/2},\ \bar{X}_n + \frac{S'_n}{\sqrt{n}}\,q_{\mathrm{St}(n-1),\,1-\alpha/2}\Big] = \Big[\bar{X}_n - \frac{S_n}{\sqrt{n-1}}\,q_{\mathrm{St}(n-1),\,1-\alpha/2},\ \bar{X}_n + \frac{S_n}{\sqrt{n-1}}\,q_{\mathrm{St}(n-1),\,1-\alpha/2}\Big].$$

L'intervalle de Student : exemple et remarques

Exemple (niveaux de bruit, TD)
$n = 20$, $\bar{x}_n = 64{,}2$, $s'_n = 5{,}15$.
Pour $\alpha = 5\%$, la table de Student donne $q_{\mathrm{St}(19),,975} = 2{,}093$, d'où l'intervalle $[61{,}8\,;\ 66{,}6]$.
Interprétation : la meilleure estimation du niveau de bruit moyen est 64,2 dB, et l'on a une confiance de 95 % dans le fait qu'il soit compris entre 61,8 et 66,6 dB.

1. Rien n'oblige à prendre un intervalle bilatéral. Nous pouvons aussi considérer les intervalles unilatéraux
$$\left[\bar{X}_n - \frac{S'_n}{\sqrt{n}}\, q_{\mathrm{St}(n-1),\,1-\alpha},\ +\infty\right[\text{ et } \left]-\infty,\ \bar{X}_n + \frac{S'_n}{\sqrt{n}}\, q_{\mathrm{St}(n-1),\,1-\alpha}\right]$$
Sur l'exemple, $]-\infty, 66{,}2]$: confiance de 95 % dans le fait que le niveau de bruit moyen est inférieur à 66,2 dB.
2. La largeur $2\,\frac{S'_n}{\sqrt{n}}\, q_{\mathrm{St}(n-1),\,1-\alpha/2}$ décroît avec n (plus d'observations, plus de précision) et avec α (moins de risque, intervalle plus large).
3. À la limite, $\alpha = 0$ donne $\hat{I}_n = \mathbb{R}$, sans intérêt : il faut parfois accepter un risque assez fort pour obtenir un intervalle utilisable.
4. $\sqrt{n}\,(\bar{X}_n - m)/S'_n$ est une fonction des observations et de m dont la loi ne dépend ni de m ni de σ^2 : la *fonction pivotale* que l'on utilisera désormais systématiquement.

Un intervalle de confiance petit signifie que l'on estime le paramètre avec précision.

IC pour la variance

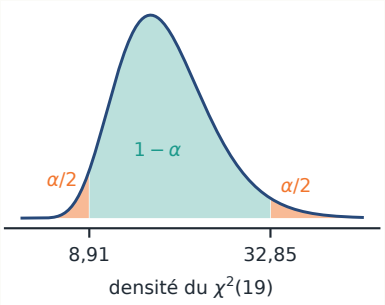
On cherche une fonction des observations et de σ^2 dont la loi ne dépende ni de m ni de σ^2. Le théorème de Fisher en donne une :

$$\frac{nS_n^2}{\sigma^2} = \frac{(n-1)S_n'^2}{\sigma^2} \sim \chi^2(n-1).$$

Pour $0 < a < b$,

$$\mathbb{P}\Big(\frac{nS_n^2}{b} \le \sigma^2 \le \frac{nS_n^2}{a}\Big) = F_{\chi^2(n-1)}(b) - F_{\chi^2(n-1)}(a).$$

χ^2 n'est pas symétrique : une infinité de (a, b) donnent $1-\alpha$.
L'usage est d'« équilibrer les risques » :
$a = q_{\chi^2(n-1),\,\alpha/2}$, $b = q_{\chi^2(n-1),\,1-\alpha/2}$.



Loi non symétrique : les deux quantiles se lisent séparément.

Proposition 3.4 (IC pour σ^2)

Un intervalle de confiance de seuil α pour le paramètre σ^2 de la loi $\mathcal{N}(m, \sigma^2)$ est

$$\Big[\frac{nS_n^2}{q_{\chi^2(n-1),\,1-\alpha/2}}, \frac{nS_n^2}{q_{\chi^2(n-1),\,\alpha/2}}\Big] = \Big[\frac{(n-1)S_n'^2}{q_{\chi^2(n-1),\,1-\alpha/2}}, \frac{(n-1)S_n'^2}{q_{\chi^2(n-1),\,\alpha/2}}\Big].$$

L'intervalle pour la variance : exemple et remarques

Exemple (niveaux de bruit)
$n = 20$, $s_n'^2 = 26{,}5$, $\alpha = 5\%$
$q_{\chi^2(19),,975} = 32{,}85$ et $q_{\chi^2(19),,025} = 8{,}91$
Nous obtenons $\sigma^2 \in [15{,}3\,;\,56{,}6]$.
Intervalle très large : la variance est bien moins précisément estimée que la moyenne.

1. Comme $\mathbb{P}(a \le \sigma^2 \le b) = \mathbb{P}(\sqrt{a} \le \sigma \le \sqrt{b})$, un intervalle de confiance de seuil α pour l'écart-type σ est
$$\left[S_n \sqrt{\frac{n}{q_{\chi^2(n-1),\,1-\alpha/2}}},\ S_n \sqrt{\frac{n}{q_{\chi^2(n-1),\,\alpha/2}}} \right].$$
2. L'intervalle est de la forme $[\varepsilon_1 S_n^2,\ \varepsilon_2 S_n^2]$ avec $\varepsilon_1 < 1 < \varepsilon_2$, et *non* de la forme $[S_n^2 - \varepsilon,\ S_n^2 + \varepsilon]$. Chercher a priori un intervalle centré sur S_n^2 n'aboutirait pas, et rien ne permettait de le prévoir.

C'est l'intérêt des fonctions pivotales : elles imposent d'elles-mêmes la forme de l'intervalle de confiance.

4.4

Intervalles de confiance

Intervalle de confiance pour une proportion

Intervalle de confiance *exact* pour une proportion

On cherche l'IC pour le paramètre p d'une loi de Bernoulli $\mathcal{B}(p)$, au vu d'un échantillon $X_1, \dots, X_n$. On rappelle que l'ESBVM de p est $\hat{p}_n = \bar{X}_n$.

Problème pratique : les sondages

Une élection oppose A et B. Un institut interroge $n = 800$ personnes : 420 déclarent voter A, 380 voter B. On pose $x_i = 1$ si la i^{e} personne vote A, 0 sinon ; on suppose les votes indépendants, de loi $\mathcal{B}(p)$ où p est la proportion de voix de A le jour de l'élection.
(Attention ! Ce n'est pas l'électeur qui vote au hasard, c'est le choix de la personne interrogée qui est aléatoire.)

Seul compte $T = \sum_i X_i$, de loi binomiale $\mathcal{B}(n, p)$. Estimation : $\hat{p}_n = 420/800 = 52{,}5\,\%$.

L'institut prédit la victoire de A, mais A demande d'avoir un intervalle de confiance de seuil 5 %.

La loi binomiale ne fournit pas de fonction pivotale simple. On admet :

Proposition 4.1

Un intervalle de confiance exact de seuil α pour p est :

$$\left[\frac{1}{1 + \frac{n-T+1}{T}\, q_{F(2(n-T+1),2T),\,1-\alpha/2}}, \frac{1}{1 + \frac{n-T}{T+1}\, q_{F(2(n-T),2(T+1)),\,\alpha/2}} \right]$$

où $q_{F(\nu_1,\nu_2),p}$ est le quantile d'ordre p de la loi de Fisher-Snedecor $F(\nu_1, \nu_2)$.

Sur l'exemple : [0,4897 ; 0,5601]. Pas vraiment significatif !

L'intervalle asymptotique

Pour n grand, le théorème de la limite centrale donne la fonction pivotale cherchée :

$$\sqrt{n}\,\frac{\hat{p}_n - p}{\sqrt{p(1-p)}} = \frac{T - np}{\sqrt{np(1-p)}} \text{ est approximativement de loi } \mathcal{N}(0,1), \qquad \text{d'où} \qquad \mathbb{P}\Big(\frac{|T - np|}{\sqrt{np(1-p)}} \leq q_{1-\alpha/2}\Big) \approx 1 - \alpha.$$

En remplaçant p par $\hat{p}_n$ dans l'écart-type :

Proposition 4.2 (IC asymptotique pour une proportion)

Un intervalle de confiance *asymptotique* de seuil α pour p est

$$\Big[\,\hat{p}_n - q_{1-\alpha/2}\sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{n}},\ \hat{p}_n + q_{1-\alpha/2}\sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{n}}\,\Big].$$

- Sur l'exemple, $q_{,975} = 1{,}96$: [0,4904 ; 0,5596], extrêmement proche de l'intervalle exact. C'est souvent le cas, d'où l'usage très répandu de l'intervalle asymptotique.
- En arrondissant : confiance de 95 % dans le fait que A obtiendra entre 49 % et 56 % des voix. L'intervalle n'est pas entièrement au-dessus de 50 % : malgré l'estimation de 52,5 %, A pourrait être battu.

Ce qui importe ici n'est pas d'estimer p, mais de décider si l'on peut admettre, avec une confiance raisonnable, que $p > 1/2$: c'est l'objet des tests d'hypothèses (chapitre 5).

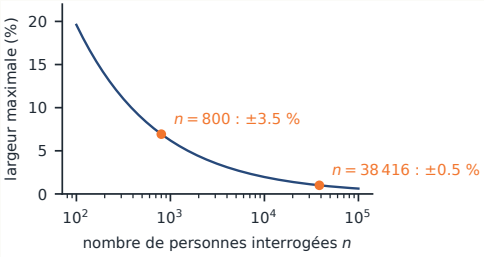
Combien de personnes faut-il interroger ?

Autre possibilité : réduire la largeur $2\, q_{1-\alpha/2}\sqrt{\hat{p}_n(1-\hat{p}_n)/n}$ de l'intervalle.
Deux choix :

- Diminuer $q_{1-\alpha/2}$: c'est augmenter α, donc la probabilité d'annoncer à tort l'élection de A.
- Augmenter n : comme $p(1-p) \leq 1/4$, nous avons que la largeur $\leq \frac{q_{1-\alpha/2}}{\sqrt{n}}$. Donc

$$n > \left(\frac{q_{1-\alpha/2}}{\ell}\right)^2 \text{ garantit une largeur } < \ell.$$

Pour $\alpha = 5\%$ et $n = 800$, nous avons $1{,}96/\sqrt{800} \approx 7\,\%$: précision de ±3,5 %, ce que l'on a constaté.
Pour une précision de ±0,5 %, il faudrait $n \geq (1{,}96/{,}01)^2 = 38\,416$ personnes, alors que les sondages en interrogent de l'ordre de 1000.



Largeur maximale de l'intervalle à 95 % en fonction de n : pour gagner un facteur 10 en précision, il faut 100 fois plus de personnes.

Toujours tenir compte du nombre de personnes interrogées pour interpréter un sondage, et se méfier des conclusions péremptoires tirées d'un échantillon de 1000 personnes.

Bilan du chapitre 4

À retenir

Un IC de seuil α pour θ est un intervalle aléatoire I avec $\mathbb{P}(\theta \in I) = 1 - \alpha$. On le construit avec une fonction pivotale, dont la loi ne dépend pas des paramètres ; sa largeur mesure la précision de l'estimation. Plus α est petit, plus l'intervalle est large ; plus n est grand, plus il est étroit (en $1/\sqrt{n}$).

Modèle	Paramètre	Estimateur	Fonction pivotale	IC de seuil α
$\mathcal{N}(m, \sigma^2)$, σ connue	m	$\bar{X}_n$	$\sqrt{n}\,\dfrac{\bar{X}_n - m}{\sigma} \sim \mathcal{N}(0,1)$	$\bar{X}_n \pm \dfrac{\sigma}{\sqrt{n}}\, q_{1-\alpha/2}$
$\mathcal{N}(m, \sigma^2)$, σ inconnue	m	$\bar{X}_n$	$\sqrt{n}\,\dfrac{\bar{X}_n - m}{S'_n} \sim \mathrm{St}(n-1)$	$\bar{X}_n \pm \dfrac{S'_n}{\sqrt{n}}\, q_{\mathrm{St}(n-1),\,1-\alpha/2}$
$\mathcal{N}(m, \sigma^2)$	σ^2	${S'_n}^2$	$\dfrac{nS_n^2}{\sigma^2} \sim \chi^2(n-1)$	$\left[\dfrac{nS_n^2}{q_{\chi^2(n-1),\,1-\alpha/2}}, \dfrac{nS_n^2}{q_{\chi^2(n-1),\,\alpha/2}}\right]$
$\mathcal{B}(p)$, n grand	p	$\hat{p}_n = \bar{X}_n$	$\dfrac{T - np}{\sqrt{np(1-p)}} \approx \mathcal{N}(0,1)$	$\hat{p}_n \pm q_{1-\alpha/2}\sqrt{\dfrac{\hat{p}_n(1-\hat{p}_n)}{n}}$

5

chapitre

Tests d'hypothèses sur un échantillon

- Introduction : le problème de décision
- Formalisation du problème de test paramétrique sur un échantillon
- Tests sur la moyenne d'une loi normale
- Tests bilatéraux et intervalles de confiance, procédure générale
- Tests sur la variance d'une loi normale
- Tests sur une proportion

5.1

Tests d'hypothèses sur un échantillon

Introduction : le problème de décision

Décider au vu d'observations

Dans tous les domaines, on doit trancher, au vu d'observations, dans un contexte incertain :

- *informatique* : au vu des tests, un nouveau système est-il assez fiable pour être mis en vente ?
- *essais thérapeutiques* : un nouveau traitement est-il meilleur que l'ancien ?
- *finance* : faut-il se lancer dans une opération donnée ?
- *santé publique* : faut-il vacciner toute une population ?
- *justice* : l'accusé est-il innocent ou coupable ?

Hypothèses et erreurs

Il s'agit de trancher entre une hypothèse nulle H_0 et une hypothèse alternative H_1, dont une et une seule est vraie. Un *test d'hypothèses* est une procédure qui permet de choisir entre les deux. Deux erreurs sont possibles :

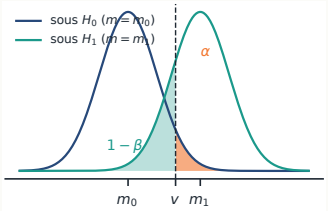
- erreur de première espèce : décider H_1 alors que H_0 est vraie ;
- erreur de seconde espèce : décider H_0 alors que H_1 est vraie.

En général, l'une des deux erreurs est plus grave que l'autre : condamner un innocent ou acquitter un coupable ; adopter un médicament pire que l'ancien ou se priver d'un meilleur ; dépenser des milliards en vaccins inutiles ou subir une pandémie.

Risques, seuil et puissance

- La probabilité de l'erreur de première espèce (rejeter H_0 à tort) est notée α : le seuil ou *niveau de signification* du test.
  (Même mot que pour les intervalles de confiance, et ce n'est pas un hasard).
- La probabilité de l'erreur de seconde espèce est notée $1 - \beta$ (« risque client »).
- β, probabilité de rejeter H_0 à raison, est la puissance du test ; $1 - \alpha$ est parfois appelé niveau de confiance.

Décision \ réalité	H_0 vraie	H_1 vraie
H_0 non rejetée	correct : $1 - \alpha$	seconde espèce : $1 - \beta$
H_1 « acceptée »	première espèce : α	puissance : β



Test de « $m = m_0$ » contre « $m > m_0$ », rejet si $\bar{x}_n > v$: en orange le risque α, en vert le risque $1 - \beta$ si la vraie moyenne est m_1.

Les deux risques varient en sens inverse. On choisit H_0 et H_1 pour que l'erreur à éviter soit celle de première espèce, et l'on fixe α : plus sa conséquence est grave, plus α est petit (10 %, 5 %, 1 %, ou bien moins).

Région critique, non-rejet et acceptation

Une règle de décision choisit entre H_0 et H_1 au vu de $x_1, \dots, x_n$, sous la contrainte que la probabilité de rejeter à tort H_0 soit égale au α fixé.

Idée naturelle : conclure que H_0 est fausse s'il est très peu probable d'observer $x_1, \dots, x_n$ quand H_0 est vraie. Une pièce est-elle truquée ? Avec 90 piles sur 100 lancers, on conclut sans hésiter qu'elle l'est. Mais avec 65 piles ?

Définition (région critique)

La région critique ou *région de rejet* W est l'ensemble des valeurs des observations $(x_1, \dots, x_n)$ pour lesquelles on rejette H_0.

- Elle dépend de α et est déterminée *a priori*, indépendamment des observations, par le bon sens ou à l'aide d'une fonction pivotale.
- Si les observations sont dans W, on rejette H_0 ; sinon, on ne la rejette pas.

« Ne pas rejeter H_0 » plutôt qu'« accepter H_0 ». Si l'on rejette H_0, c'est qu'il est très improbable qu'elle soit vraie. Si l'on ne la rejette pas, c'est que l'on manque de critères pour dire qu'elle est fausse ; cela ne veut pas dire que H_0 est vraie ! Sans preuve de culpabilité, un accusé n'est pas forcément innocent.

Un test permet de dire qu'une hypothèse est *très probablement fausse*, ou seulement *peut-être vraie*. On choisit donc H_0 et H_1 de façon à ce que le rejet de H_0 soit la conclusion intéressante.

Choisir H_0 et H_1 : exemples

Exemple 1 (choix de H_0 et H_1)

Dans chaque cas, le rejet de H_0 doit être la conclusion que l'on cherche à établir, avec un risque α contrôlé.

1. Au vu d'analyses sanguines, on souhaite prouver qu'un sportif se dope :
   H_0 : « le sportif ne se dope pas » contre H_1 : « le sportif se dope ».
2. Le sportif veut prouver qu'il ne se dope pas :
   H_0 : « le sportif se dope » contre H_1 : « le sportif ne se dope pas ».
3. On veut s'assurer qu'un patient est guéri avant de le laisser partir :
   H_0 : « le patient n'est pas guéri » contre H_1 : « le patient est guéri ».
4. On veut vérifier qu'un vaccin B a moins d'effets indésirables qu'un vaccin A :
   H_0 : « B a au moins autant d'effets indésirables que A » contre H_1 : « B en a moins ».

Les deux premiers cas montrent que le choix des hypothèses dépend de *qui* doit apporter la preuve : le même problème donne deux tests différents, et des conclusions qui ne sont pas symétriques.

La démarche en cinq étapes

Pour effectuer un test d'hypothèses

1. Choisir H_0 et H_1 de sorte que ce qui importe soit le rejet de H_0.
2. Fixer α selon la gravité des conséquences de l'erreur de première espèce.
3. Déterminer la région critique W (elle fait intervenir des fonctions pivotales).
4. Regarder si les observations sont ou non dans W.
5. Conclure au rejet ou au non-rejet de H_0.

- Pour un même problème, plusieurs tests (plusieurs régions critiques) de même seuil sont souvent possibles. Le meilleur est celui qui minimise l'erreur de seconde espèce, donc maximise la puissance β : le test le plus puissant. On peut parfois le déterminer, pas toujours.
- Quand les hypothèses portent sur la valeur d'un paramètre d'une loi, le test est paramétrique : par exemple, pour l'élection, trancher entre « $p \leq 1/2$ » et « $p > 1/2$ ». Les autres tests sont *non paramétriques* (test du χ^2).

Ce chapitre traite les tests paramétriques sur *un* échantillon ; le chapitre 6 présente le plus célèbre des tests, le test du χ^2.

Tests d'hypothèses sur un échantillon

5.2 Formalisation du problème de test paramétrique sur un échantillon

Hypothèses simples et composites

$x_1, \dots, x_n$ réalisations de $X_1, \dots, X_n$ iid, de loi dépendant d'un paramètre *réel* inconnu θ.

Une hypothèse est simple si elle est du type « $\theta = \theta_0$ », composite si elle est du type « $\theta \in A$ », $A \subset \mathbb{R}$ non réduit à un point.

Tests d'hypothèses simples (cas d'école)

H_0 : « $\theta = \theta_0$ » contre H_1 : « $\theta = \theta_1$ ». Seuil et puissance :

$$\alpha = \mathbb{P}\big((X_1, \dots, X_n) \in W \,;\, \theta_0\big),$$

$$\beta = \mathbb{P}\big((X_1, \dots, X_n) \in W \,;\, \theta_1\big).$$

Il ignore la possibilité que θ ne soit ni θ_0 ni θ_1.

Tests d'hypothèses composites (cas usuels)

- test bilatéral : « $\theta = \theta_0$ » contre « $\theta \neq \theta_0$ » ;
- tests unilatéraux : « $\theta \leq \theta_0$ » contre « $\theta > \theta_0$ », ou « $\theta \geq \theta_0$ » contre « $\theta < \theta_0$ ».

H_0 et H_1 sont complémentaires : l'une est forcément vraie.

Définition 2.1

- La puissance du test est la fonction β définie par $\beta(\theta) = \mathbb{P}\big((X_1, \dots, X_n) \in W \,;\, \theta\big)$: la probabilité de rejeter H_0 quand la vraie valeur du paramètre est θ.
- Le seuil du test est $\alpha = \max_{H_0} \beta(\theta)$: la plus forte probabilité de rejeter H_0 à tort.

Test bilatéral : $\alpha = \beta(\theta_0)$; premier test unilatéral : $\alpha = \sup_{\theta \leq \theta_0} \beta(\theta)$.

5.3

Tests d'hypothèses sur un échantillon

Tests sur la moyenne d'une loi normale

Le cas simple : un test bilatéral, variance connue

$X_1, \dots, X_n$ iid de loi $\mathcal{N}(m, \sigma^2)$ (ou telle que le TCL s'applique), m inconnue, σ^2 connue.

On teste H_0 : « $m = m_0$ » contre H_1 : « $m \neq m_0$ ».

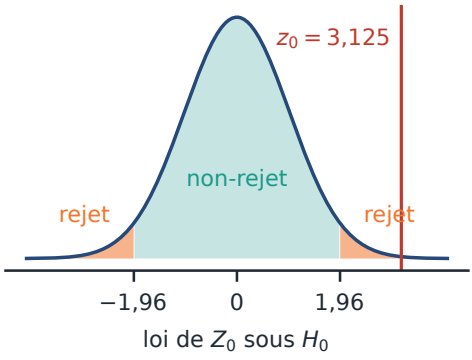
Si H_0 est vraie, $\bar{X}_n \sim \mathcal{N}(m_0, \sigma^2/n)$, et

$$Z_0 = \frac{\bar{X}_n - m_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1) \text{ sous } H_0.$$

Une valeur de Z_0 dans les extrémités de la distribution est peu probable si H_0 est vraie : on aura raison de remettre H_0 en doute.

Critère de rejet (test bilatéral, σ connue)

On rejette H_0 si $z_0 < q_{\alpha/2}$ ou $z_0 > q_{1-\alpha/2}$, et on ne la rejette pas si $q_{\alpha/2} \leq z_0 \leq q_{1-\alpha/2}$.
En termes de $\bar{x}_n$, les valeurs critiques sont $v_{1,2} = m_0 \pm q_{1-\alpha/2}\, \sigma/\sqrt{n}$.



Région critique à $\alpha = 5\%$ et valeur observée de l'exemple 2.

Exemple

Exemple 2 (carburant de fusée)

Le cahier des charges exige une vitesse moyenne de combustion de 40 cm/s. L'écart-type vaut environ $\sigma = 2$ cm/s et la vitesse suit une loi normale.

1. *Hypothèses et seuil :* H_0 : « $m = 40$ » contre H_1 : « $m \neq 40$ », $\alpha = 0{,}05$, échantillon de taille $n = 25$.
2. *Règle de rejet :* test bilatéral, on rejette H_0 si $\bar{x}_n$ est trop grand ou trop petit par rapport à 40, soit si $|z_0| > q_{0{,}975} = 1{,}96$.
3. *Statistique observée :* $\bar{x}_n = 41{,}25$ cm/s, donc
$$z_0 = \frac{\bar{x}_n - m_0}{\sigma/\sqrt{n}} = \frac{41{,}25 - 40}{2/\sqrt{25}} = 3{,}125.$$
4. *Décision :* $3{,}125 > 1{,}96$, donc z_0 est dans la région critique : on rejette H_0.
5. *Conclusion :* la vitesse moyenne de combustion s'écarte de 40 cm/s de façon significative au seuil de 5 %.

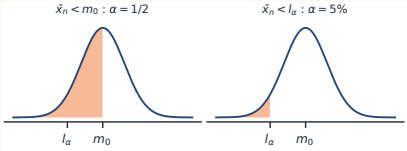
Les cinq étapes de la démarche, dans l'ordre : hypothèses et seuil, règle, calcul, décision, conclusion *en français*.

Un test unilatéral : l'essai thérapeutique

Avec un médicament A, la durée de disparition d'un mal de tête est de loi $\mathcal{N}(m_0, \sigma_0^2)$, $m_0 = 30$ mn, $\sigma_0 = 5$ mn. Un nouveau médicament B est testé sur n malades : durées $x_1, \dots, x_n$, de loi $\mathcal{N}(m, \sigma^2)$.

- « $m = m_0$ » : B a en moyenne *le même effet* que A ;
- « $m < m_0$ » : B est en moyenne *plus efficace* que A ;
- « $m > m_0$ » : B est en moyenne *moins efficace* que A.

Mieux vaut garder un médicament moins performant que le nouveau, qu'adopter un médicament moins performant que l'ancien : « $m < m_0$ » doit correspondre au rejet de H_0. On teste H_0 : « $m \geq m_0$ » contre H_1 : « $m < m_0$ ».



Loi de $\bar{X}_n$ sous $m = m_0$ et les deux régions critiques envisagées.

Première idée

$\bar{X}_n$ est l'ESBVM de m : conclure $m < m_0$ si et seulement si $\bar{x}_n < m_0$, soit $W = \{\bar{x}_n < m_0\}$. Comme $\sqrt{n}\,(\bar{X}_n - m)/\sigma \sim \mathcal{N}(0,1)$,

$$\alpha = \sup_{m \geq m_0} \mathbb{P}\big(\bar{X}_n < m_0\,;\, m\big) = \sup_{m \geq m_0} \Phi\Big(\sqrt{n}\,\frac{m_0 - m}{\sigma}\Big) = \Phi(0) = \frac{1}{2}.$$

Une chance sur deux de se tromper : beaucoup trop.

Deuxième idée : rejeter si $\bar{x}_n$ est significativement plus petit

On prend $W = \{\bar{x}_n < l_\alpha\}$ avec $l_\alpha < m_0$ dépendant du seuil : moins on veut risquer de rejeter à tort H_0, plus α et l_α sont petits. Le même calcul donne

$$\alpha = \sup_{m \geq m_0} \Phi\Big(\sqrt{n}\,\frac{l_\alpha - m}{\sigma}\Big) = \Phi\Big(\sqrt{n}\,\frac{l_\alpha - m_0}{\sigma}\Big), \qquad \text{d'où} \qquad l_\alpha = m_0 + \frac{\sigma}{\sqrt{n}}\,\Phi^{-1}(\alpha) = m_0 - \frac{\sigma}{\sqrt{n}}\,q_{1-\alpha}.$$

Proposition 3.1 (test unilatéral, σ connue)

Un test de seuil α de H_0 : « $m \geq m_0$ » contre H_1 : « $m < m_0$ » est déterminé par la région critique

$$W = \Big\{\bar{x}_n < m_0 - \frac{\sigma}{\sqrt{n}}\,q_{1-\alpha}\Big\}, \qquad q_{1-\alpha} \text{ quantile d'ordre } 1-\alpha \text{ de } \mathcal{N}(0,1).$$

Le sens de « significativement »

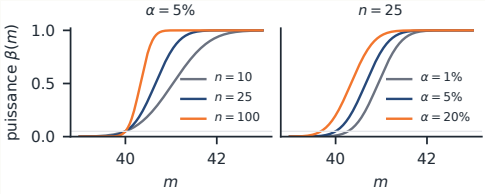
« $\bar{x}_n$ significativement plus petit que m_0 » signifie $\bar{x}_n < l_\alpha$: l'écart $m_0 - \bar{x}_n$ dépasse ce que les fluctuations de $\bar{X}_n$ produisent, sous H_0, avec probabilité α. Le mot n'a de sens que relativement au seuil.

Risque de deuxième espèce et puissance

L'analyste choisit α directement, mais l'erreur de deuxième espèce compte aussi. Pour H_0 : « $m = m_0$ » contre H_1 : « $m > m_0$ », on rejette si $\bar{x}_n > v = m_0 + q_{1-\alpha}\,\sigma/\sqrt{n}$. Si la vraie moyenne est $m_1 > m_0$, $\bar{X}_n \sim \mathcal{N}(m_1, \sigma^2/n)$ et l'erreur de deuxième espèce se produit si $\bar{x}_n < v$:

$$1 - \beta = \mathbb{P}(\bar{X}_n < v\,;\, m_1) = \Phi\Big(\sqrt{n}\,\frac{v - m_1}{\sigma}\Big).$$

Le risque $1-\beta$ **diminue** quand m_1 s'éloigne de m_0, quand n augmente, et quand α augmente.
La puissance β dépend de H_1 (un test unilatéral est plus puissant qu'un bilatéral), augmente avec n, diminue avec α. Il est courant de fixer β et d'en déduire la taille d'échantillon nécessaire.



Fonction puissance $m \mapsto \beta(m)$ du test « $m \le 40$ » contre « $m > 40$ », $\sigma = 2$: au plus α sous H_0, tend vers 1 sous H_1 d'autant plus vite que n est grand.

Exercice 1 (carburant de fusée, test unilatéral à droite)

H_0 : « $m = 40$ » contre H_1 : « $m > 40$ », $\alpha = 5\%$, $n = 25$.
Montrer que la puissance vaut 80,5 % si la vraie vitesse est $m_1 = 41$.
Indication : commencer par $1 - \beta = \mathbb{P}(\text{ne pas rejeter } H_0 \mid H_1 \text{ vraie})$.

Troisième idée : variance inconnue, test de Student

La proposition 3.1 est inutilisable sans la vraie valeur de σ.

Comme pour les intervalles de confiance, on remplace σ par S'_n et la loi normale par la loi de Student : $\sqrt{n}\,(\bar{X}_n - m)/S'_n \sim \mathrm{St}(n-1)$. Avec $W = \{\bar{x}_n < l_\alpha\}$,

$$\alpha = \sup_{m \geq m_0} \mathbb{P}\left(\sqrt{n}\,\frac{\bar{X}_n - m}{S'_n} < \sqrt{n}\,\frac{l_\alpha - m}{S'_n}\,;\, m\right) = F_{\mathrm{St}(n-1)}\left(\sqrt{n}\,\frac{l_\alpha - m_0}{S'_n}\right) \quad \Longrightarrow \quad l_\alpha = m_0 - \frac{S'_n}{\sqrt{n}}\, q_{\mathrm{St}(n-1),\,1-\alpha}.$$

Proposition 3.2 (test unilatéral, σ inconnue)
Un test de seuil α de H_0 : « $m \geq m_0$ » contre H_1 : « $m < m_0$ » est déterminé par la région critique

$$W = \left\{\bar{x}_n < m_0 - \frac{s'_n}{\sqrt{n}}\, q_{\mathrm{St}(n-1),\,1-\alpha}\right\} = \left\{\sqrt{n}\,\frac{\bar{x}_n - m_0}{s'_n} < -q_{\mathrm{St}(n-1),\,1-\alpha}\right\}.$$

La seconde forme fait apparaître la fonction pivotale $\sqrt{n}\,(\bar{X}_n - m_0)/S'_n$, déjà vue pour les intervalles de confiance ; c'est celle que l'on conservera.

Essai thérapeutique : test de Student

Le médicament B, a été administré à 12 malades pour des durées

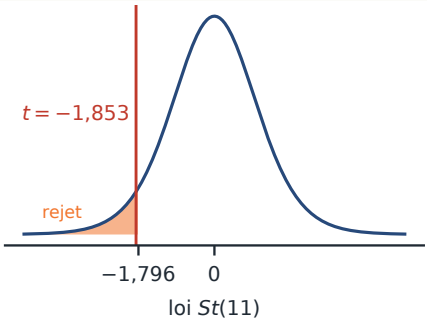
$$25, 28, 20, 32, 17, 24, 41, 28, 25, 30, 27, 24$$

On a $\bar{x}_n = 26{,}75$ et $s'_n = 6{,}08$.
On ne commercialise B que si l'on est sûr à 95 % qu'il est plus efficace : test de « $m \geq 30$ » contre « $m < 30$ » au seuil 5%.

$$\sqrt{12}\,\frac{26{,}75 - 30}{6{,}08} = -1{,}853 < -q_{\mathrm{St}(11),\,0{,}95} = -1{,}796.$$

On est dans la région critique : on rejette H_0.

Conclusion : B est plus efficace que A avec moins de 5 % de chances de se tromper. On peut lancer la commercialisation.



Région critique au seuil 5 % et statistique observée, juste à gauche de $-q_{\mathrm{St}(11),\,0{,}95}$.

Le rôle fondamental du seuil.

- Avec $\alpha = 1\%$, $q_{\mathrm{St}(11),\,0{,}99} = 2{,}718$ et $-1{,}853 > -2{,}718$: on n'aurait pas rejeté H_0, donc pas adopté B.
- C'est normal : un α petit revient à éviter au maximum d'adopter B à tort, et le moyen le plus sûr est de garder A.
- Le test de seuil $\alpha = 0$ garde A quelles que soient les observations. Le principe de précaution conduit au conservatisme : il faut choisir α en connaissance de cause.

La p-valeur

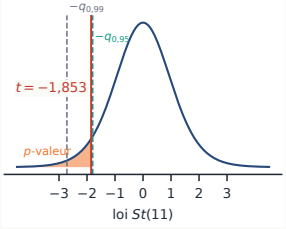
Définition
La p-valeur est le seuil critique α_c tel que l'on rejette H_0 pour tout $\alpha > \alpha_c$ et ne la rejette pas pour tout $\alpha < \alpha_c$.

Sur l'exemple, α_c vérifie

$$\sqrt{n}\,\frac{\bar{x}_n - m_0}{s'_n} = -q_{\mathrm{St}(n-1),\,1-\alpha_c} = q_{\mathrm{St}(n-1),\,\alpha_c}$$

$$\Longrightarrow \quad \alpha_c = F_{\mathrm{St}(n-1)}\left(\sqrt{n}\,\frac{\bar{x}_n - m_0}{s'_n}\right) = F_{\mathrm{St}(11)}(-1{,}853) = 0{,}0455.$$

- La p-valeur est la probabilité, sous H_0, d'observer une statistique au moins aussi extrême que celle observée.
- Pour tout seuil supérieur à 4,5 % (par exemple 5 %), on rejette H_0 ; pour tout seuil inférieur (par exemple 1 %), on ne la rejette pas. À 1 %, on conclut que rien ne prouve que B est plus efficace que A, et non que A est plus efficace que B.
- La réponse d'un test à seuil fixé est binaire. La p-valeur est plus riche : elle donne le résultat pour *tous* les seuils. C'est ce que fournissent les logiciels (`t.test` en R, option `alternative` pour choisir entre le test bilatéral et les deux unilatéraux).



En orange, la p-valeur : 4,55 %, entre 1 % et 5 %.

Plus la p-valeur est petite, moins on prend de risque en rejetant H_0.

Les tests de Student

Par symétrie, « $m \leq m_0$ » contre « $m > m_0$ » se traite de même.

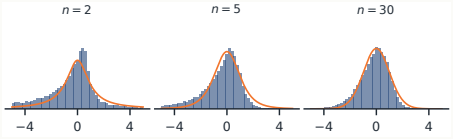
Pour le test bilatéral, on rejette si $\bar{x}_n$ est significativement *éloigné* de m_0 :

$$W = \{|\bar{x}_n - m_0| > l_\alpha\}, \text{ avec } l_\alpha = s'_n \, q_{\mathrm{St}(n-1),\,1-\alpha/2}/\sqrt{n}.$$

Théorème 3.3 (tests de Student sur la moyenne d'une loi normale)

- Test de « $m \leq m_0$ » contre « $m > m_0$ » : $W = \left\{\sqrt{n}\,(\bar{x}_n - m_0)/s'_n > q_{\mathrm{St}(n-1),\,1-\alpha}\right\}$.
- Test de « $m \geq m_0$ » contre « $m < m_0$ » : $W = \left\{\sqrt{n}\,(\bar{x}_n - m_0)/s'_n < -q_{\mathrm{St}(n-1),\,1-\alpha}\right\}$.
- Test de « $m = m_0$ » contre « $m \neq m_0$ » : $W = \left\{\sqrt{n}\,|\bar{x}_n - m_0|\,/s'_n > q_{\mathrm{St}(n-1),\,1-\alpha/2}\right\}$.

Robustesse à la non-normalité. Par le théorème central limite, pour n assez grand, $\bar{X}_n$ est approximativement gaussienne quelle que soit la loi des observations. En pratique, pour $n \geq 30$, le test de Student s'applique à la moyenne de n'importe quelle loi.



$\sqrt{n}\,(\bar{X}_n - m)/S'_n$ pour des observations exponentielles (histogrammes) contre $\mathrm{St}(n-1)$ (courbe) : l'écart disparaît quand n grandit.

Tests d'hypothèses sur un échantillon

5.4 Tests bilatéraux et intervalles de confiance, procédure générale

Tests bilatéraux et intervalles de confiance

Dualité

Si $[L, U]$ est un intervalle de confiance de niveau $1 - \alpha$ pour θ, le test de seuil α de H_0 : « $\theta = \theta_0$ » contre H_1 : « $\theta \neq \theta_0$ » rejette H_0 si et seulement si $\theta_0 \notin [L, U]$.

Exemple 3

Un intervalle de confiance à 95 % pour la moyenne d'une population est $[41, 43]$. Comme $40 \notin [41, 43]$, un test sur le même échantillon rejettera H_0 : « $m = 40$ » au seuil 5%, au profit de l'alternative bilatérale.

Procédure générale pour construire un test sur θ

Si l'on connaît un estimateur $\hat{\theta}_n$ de θ, le bon sens donne la forme de la région critique :

- « $\theta \leq \theta_0$ » contre « $\theta > \theta_0$ » : on rejette si $\hat{\theta}_n$ est « trop grand », $W = \{\hat{\theta}_n > l_\alpha\}$;
- « $\theta \geq \theta_0$ » contre « $\theta < \theta_0$ » : on rejette si $\hat{\theta}_n$ est « trop petit », $W = \{\hat{\theta}_n < l_\alpha\}$;
- « $\theta = \theta_0$ » contre « $\theta \neq \theta_0$ » : $W = \{\hat{\theta}_n < l_{1,\alpha}$ ou $\hat{\theta}_n > l_{2,\alpha}\}$, $l_{1,\alpha} < l_{2,\alpha}$.

Les bornes viennent de $\alpha = \sup_{H_0} \mathbb{P}\big((X_1, \dots, X_n) \in W\,;\, \theta\big)$, ce qui demande une *fonction pivotale*.

Limites de la procédure, et le sens du non-rejet

- Cette procédure de bon sens échoue quand la loi de $\hat{\theta}_n$ sous H_0 est trop complexe pour fournir une fonction pivotale, et le test obtenu n'est pas forcément le plus puissant. Des méthodes plus sophistiquées répondent à ces deux problèmes ; le résultat le plus important est le *théorème de Neyman-Pearson*, hors programme.

« Non-rejet ≠ acceptation », selon le type de test

- **Tests unilatéraux :** la différence est franche. « B n'est pas plus efficace que A » n'est pas « B est moins efficace que A ».
- **Tests bilatéraux :** H_0 est une hypothèse simple, donc accepter H_0 revient à choisir le modèle $\theta = \theta_0$ pour le phénomène étudié. Or tous les modèles sont faux, car ce ne sont que des approximations de la réalité. Ne pas rejeter H_0, c'est considérer que ce modèle n'est pas absurde ; on peut donc l'adopter, ce qui revient en quelque sorte à « accepter » H_0, au sens où le modèle sous-jacent n'est pas trop mauvais.

Même fonction pivotale, deux usages : encadrer θ (intervalle de confiance) ou décider sur θ (test).

5.5

Tests d'hypothèses sur un échantillon

Tests sur la variance d'une loi normale

Tests sur la variance

$X_1, \dots, X_n$ iid de loi $\mathcal{N}(m, \sigma^2)$. Pour tester H_0 : « $\sigma^2 \leq \sigma_0^2$ » contre H_1 : « $\sigma^2 > \sigma_0^2$ », l'ESBVM de σ^2 étant ${S'_n}^2$, on rejette H_0 si ${s'_n}^2$ est trop grand : $W = \{{s'_n}^2 > l_\alpha\}$.

Avec la fonction pivotale $(n-1){S'_n}^2/\sigma^2 \sim \chi^2(n-1)$,

$$\alpha = \sup_{\sigma^2 \leq \sigma_0^2} \mathbb{P}\Big(\frac{(n-1){S'_n}^2}{\sigma^2} > \frac{(n-1)l_\alpha}{\sigma^2}\Big) = \sup_{\sigma^2 \leq \sigma_0^2} \Big[1 - F_{\chi^2(n-1)}\Big(\frac{(n-1)l_\alpha}{\sigma^2}\Big)\Big] = 1 - F_{\chi^2(n-1)}\Big(\frac{(n-1)l_\alpha}{\sigma_0^2}\Big), \quad \text{d'où } l_\alpha = \frac{\sigma_0^2}{n-1} q_{\chi^2(n-1),\,1-\alpha}.$$

On aboutirait au même résultat en partant d'un intervalle de confiance unilatéral $[a, +\infty[$ pour σ^2.

Théorème 6.1 (tests sur la variance d'une loi normale)

- Test de « $\sigma^2 \leq \sigma_0^2$ » contre « $\sigma^2 > \sigma_0^2$ » : $W = \Big\{\frac{(n-1){s'_n}^2}{\sigma_0^2} > q_{\chi^2(n-1),\,1-\alpha}\Big\}$.
- Test de « $\sigma^2 \geq \sigma_0^2$ » contre « $\sigma^2 < \sigma_0^2$ » : $W = \Big\{\frac{(n-1){s'_n}^2}{\sigma_0^2} < q_{\chi^2(n-1),\,\alpha}\Big\}$.
- Test de « $\sigma^2 = \sigma_0^2$ » contre « $\sigma^2 \neq \sigma_0^2$ » : $W = \Big\{\frac{(n-1){s'_n}^2}{\sigma_0^2} < q_{\chi^2(n-1),\,\alpha/2} \text{ ou } \frac{(n-1){s'_n}^2}{\sigma_0^2} > q_{\chi^2(n-1),\,1-\alpha/2}\Big\}$.

Contrairement à la moyenne, ces tests ne s'étendent pas aux lois non normales : il n'y a pas d'équivalent du théorème central limite pour ${S'_n}^2$.

Exemple

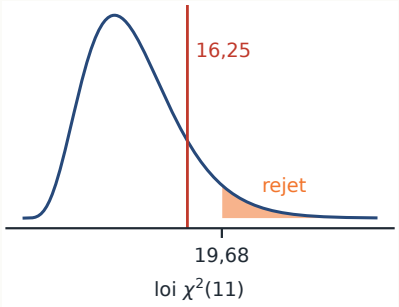
Exemple (variabilité du médicament B)

La variance mesure la variabilité de l'effet du médicament : faible si l'effet est à peu près le même pour tout le monde, forte s'il diffère beaucoup d'un individu à l'autre. On a intérêt à une variabilité faible pour bien contrôler un traitement.

Avec A, $\sigma_0 = 5$ mn : pour 95 % des malades, la douleur disparaît entre $m_0 - 2\sigma_0 = 20$ et $m_0 + 2\sigma_0 = 40$ mn. Avec B, on estime $s'_n = 6{,}08$ mn. La variabilité de B est-elle significativement supérieure ? Test de « $\sigma \leq 5$ » contre « $\sigma > 5$ », soit « $\sigma^2 \leq 25$ » contre « $\sigma^2 > 25$ », au seuil 5 % :

$$\frac{(n-1)s'^2_n}{\sigma_0^2} = \frac{11 \times 6{,}08^2}{25} = 16{,}25 < q_{\chi^2(11),\,0{,}95} = 19{,}68.$$

On ne rejette pas H_0 : la différence entre 6,08 et 5 n'est pas significative au seuil choisi.



Région critique du $\chi^2(11)$ au seuil 5 % et statistique observée.

La p-valeur s'obtient en écrivant $q_{\chi^2(n-1),\,1-\alpha_c} = 16{,}25$, soit $\alpha_c = 1 - F_{\chi^2(11)}(16{,}25) = 13{,}2$ % : même au seuil 10 %, on ne rejette pas H_0.

5.6

Tests d’hypothèses sur un échantillon

Tests sur une proportion

Tests sur une proportion

$X_1, \dots, X_n$ iid de loi $\mathcal{B}(p)$, $T = \sum_i X_i \sim \mathcal{B}(n, p)$.

Vu la complexité de l'intervalle exact du chapitre 4, on se contente de la fonction pivotale asymptotique $(T - np)/\sqrt{np(1-p)} \approx \mathcal{N}(0,1)$, qui donne directement les tests.

Théorème 7.1 (tests asymptotiques sur une proportion)

- Test de « $p \leq p_0$ » contre « $p > p_0$ » : $W = \left\{ \dfrac{t - np_0}{\sqrt{np_0(1-p_0)}} > q_{1-\alpha} \right\}$.
- Test de « $p \geq p_0$ » contre « $p < p_0$ » : $W = \left\{ \dfrac{t - np_0}{\sqrt{np_0(1-p_0)}} < -q_{1-\alpha} \right\}$.
- Test de « $p = p_0$ » contre « $p \neq p_0$ » : $W = \left\{ \dfrac{|t - np_0|}{\sqrt{np_0(1-p_0)}} > q_{1-\alpha/2} \right\}$.

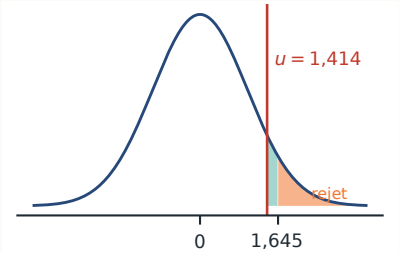
Exemple

Exemple (le sondage, suite)

$n = 800$, $t = 420$, $\hat{p}_n = 52{,}5\,\%$, intervalle à 95 % [49 %, 56 %], en partie sous les 50 %. La seule chose qui intéresse A est de savoir s'il sera élu : le rejet de H_0 doit correspondre à son élection, on teste « $p \leq 1/2$ » contre « $p > 1/2$ ».

$$\frac{t - np_0}{\sqrt{np_0(1-p_0)}} = \frac{420 - 400}{\sqrt{800/4}} = 1{,}414 < q_{0{,}95} = 1{,}645.$$

On ne rejette pas H_0 : on ne peut pas affirmer que A sera élu avec moins de 5 % de chances de se tromper.



loi $\mathcal{N}(0,1)$; en vert et orange : la p-valeur

Région critique au seuil 5 % et statistique observée.

La p-valeur asymptotique est le α_c tel que $q_{1-\alpha_c} = 1{,}414$, soit $\alpha_c = 1 - \Phi(1{,}414) = 7{,}86\,\%$. Le test exact (`binom.test` en R) donne 8,39 %, cohérent.

Conclure à l'élection de A, c'est prendre au pire 8,4 % de chances de se tromper, si le sondage est représentatif du jour du vote, ce qui est loin d'être certain.

Bilan du chapitre 5

À retenir

- Un test oppose H_0 et H_1 ; on contrôle le risque de première espèce $\alpha = \max_{H_0} \beta(\theta)$ et l'on choisit les hypothèses pour que *rejeter* H_0 soit la conclusion intéressante. Ne pas rejeter n'est pas accepter.
- La région critique est fixée a priori ; sa borne vient d'une fonction pivotale, la même que pour les intervalles de confiance. Test bilatéral de seuil $\alpha \iff \theta_0$ hors de l'IC de seuil α.
- La p-valeur est le seuil critique α_c : on rejette H_0 au seuil α si et seulement si $\alpha > \alpha_c$.
- La puissance augmente avec n et avec l'écart entre H_0 et la vraie valeur, diminue quand α diminue.

Paramètre	Statistique de test	Loi sous H_0	Rejet de « $\theta \leq \theta_0$ » / « $\theta = \theta_0$ »
m, σ connue	$z_0 = \sqrt{n}\,(\bar{x}_n - m_0)/\sigma$	$\mathcal{N}(0,1)$	$z_0 > q_{1-\alpha}$ / $\lvert z_0 \rvert > q_{1-\alpha/2}$
m, σ inconnue	$t = \sqrt{n}\,(\bar{x}_n - m_0)/s'_n$	$\mathrm{St}(n-1)$	$t > q_{\mathrm{St}(n-1),\,1-\alpha}$ / $\lvert t \rvert > q_{\mathrm{St}(n-1),\,1-\alpha/2}$
σ^2	$c = (n-1)s'^2_n/\sigma_0^2$	$\chi^2(n-1)$	$c > q_{\chi^2(n-1),\,1-\alpha}$ / $c \notin [q_{\chi^2(n-1),\,\alpha/2}, q_{\chi^2(n-1),\,1-\alpha/2}]$
p (n grand)	$u = (t - np_0)/\sqrt{np_0(1-p_0)}$	$\approx \mathcal{N}(0,1)$	$u > q_{1-\alpha}$ / $\lvert u \rvert > q_{1-\alpha/2}$

6

chapitre

Tests du chi-deux

Un dé est-il équilibré ?

Exemple 4 (un dé est-il équilibré ?)
On jette un dé 300 fois :

face obtenue	1	2	3	4	5	6
nombre de lancers	42	43	56	55	43	61

Si le dé est équilibré, on s'attend à environ $300/6 = 50$ fois chaque face. 61 fois la face 6 et 42 fois la face 1 : est-ce trop pour un dé équilibré ?
Idée : rejeter si la « distance » entre $(42, 43, 56, 55, 43, 61)$ et $(50, \dots, 50)$ est trop grande. Reste à choisir la distance.

Cadre général. Une expérience a k issues possibles, de probabilités $p_1, \dots, p_k$ sous H_0 ($\sum_j p_j = 1$). On répète n fois l'expérience et l'on compte les effectifs n_j de chaque issue ($\sum_j n_j = n$). Sous H_0, on attend en moyenne np_j fois l'issue j, d'où une région critique de la forme $\{\sum_j (n_j - np_j)^2 > l_\alpha\}$, qui demande la loi de $\sum_j (N_j - np_j)^2$ ou d'une variable analogue.

$$\mathbb{P}(N_1 = n_1, \dots, N_k = n_k) = \frac{n!}{n_1! \cdots n_k!} p_1^{n_1} \cdots p_k^{n_k} :$$

le vecteur $(N_1, \dots, N_k)$ suit la loi multinomiale $\mathcal{M}(n; p_1, \dots, p_k)$.

Le théorème de Pearson et le test du χ^2

Théorème 2.1 (théorème de Pearson)

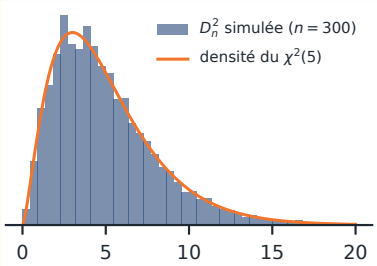
Si $(N_1, \dots, N_k) \sim \mathcal{M}(n; p_1, \dots, p_k)$, alors

$$D_n^2 = \sum_{j=1}^{k} \frac{(N_j - np_j)^2}{np_j} \xrightarrow[n\to+\infty]{\mathcal{L}} \chi^2(k-1).$$

Définition 2.1 (test du chi-deux)

Le test de H_0 : « les probabilités des k issues sont $p_1, \dots, p_k$ » contre $H_1 = \overline{H_0}$ défini par la région critique

$$W = \left\{ \sum_{j=1}^{k} \frac{(n_j - np_j)^2}{np_j} > q_{\chi^2(k-1),\,1-\alpha} \right\}.$$



Le théorème de Pearson sur le dé : loi de D_n^2 pour un dé équilibré (20 000 séries de 300 lancers simulées) et densité du $\chi^2(5)$.

Chaque écart est pondéré par l'effectif attendu. Le théorème de Pearson n'est qu'asymptotique : en pratique, on n'effectue le test que si les effectifs attendus vérifient $np_j \geq 5$ pour tout j.

Le dé, suite et fin

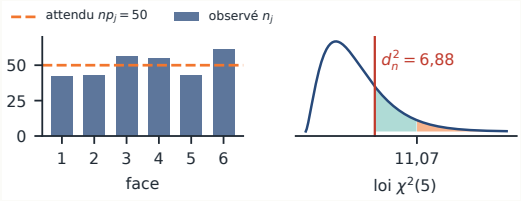
Exemple 4 (suite)

H_0 : « $p_j = 1/6$ pour tout j », $k = 6$, $n = 300$:

$$d_n^2 = \frac{(42-50)^2}{50} + \cdots + \frac{(61-50)^2}{50} = 6{,}88.$$

Au seuil 5 %, $q_{\chi^2(5),,95} = 11{,}07$ et $6{,}88 \ll 11{,}07$: on ne rejette pas H_0, rien n'indique que le dé n'est pas équilibré.

`chisq.test` donne la p-valeur 23 % : même en s'autorisant 20 % de chances de se tromper, on ne rejetterait pas H_0. Pour un dé équilibré, observer 61 fois la face 6 n'a donc rien d'improbable, même si l'on ne s'attend qu'à 50 en moyenne.



Effectifs observés et attendus, puis la statistique observée face à la région critique du $\chi^2(5)$; l'aire verte et orange est la p-valeur.

Le théorème de Pearson permet en fait de tester l'adéquation d'un échantillon à une loi, entièrement spécifiée ou dans une famille.

Test d'adéquation du χ^2 à une loi entièrement spécifiée

Les observations $x_1, \dots, x_n$ peuvent-elles être considérées comme des réalisations de $X_1, \dots, X_n$ iid de loi donnée (normale, exponentielle, binomiale…) ?

L'histogramme et le graphe de probabilités donnent une réponse visuelle, sans quantifier l'erreur commise. Un *test d'adéquation* (ou d'ajustement) répond à ce problème.

On devrait toujours en appliquer un avant d'utiliser un modèle probabiliste ; en pratique on ne le fait pas toujours, d'où parfois des modèles complètement erronés.

Loi entièrement spécifiée

F fonction de répartition inconnue des X_i ; tester H_0 : « $F = F_0$ » contre H_1 : « $F \neq F_0$ ». Exemples : les observations sont-elles issues d'une $\mathcal{N}(10, 4)$? un générateur de nombres aléatoires produit-il bien une loi uniforme sur $[0, 1]$?

- *Variables discrètes* : les observations prennent k valeurs $e_1, \dots, e_k$, n_j est le nombre d'observations égales à e_j, et sous H_0, $p_j = \mathbb{P}(X = e_j)$ se calcule. $(N_1, \dots, N_k) \sim \mathcal{M}(n; p_1, \dots, p_k)$: théorème de Pearson.
- *Variables continues* : on regroupe les observations en k classes $]a_{j-1}, a_j]$, comme pour un histogramme, et sous H_0, $p_j = \mathbb{P}(a_{j-1} < X \leq a_j) = F_0(a_j) - F_0(a_{j-1})$. On est à nouveau dans le cadre du théorème de Pearson.

Le nombre de classes conseillé n'est pas celui de l'histogramme : en pratique $k \approx 2n^{2/5}$, avec au moins 5 observations attendues par classe ($np_j \geq 5$). Les deux règles réunies demandent une cinquantaine d'observations pour un test du χ^2 dans de bonnes conditions.

Test d'adéquation du χ^2 à une famille de lois

Tester H_0 : « $F \in \mathcal{F}$ » contre H_1 : « $F \notin \mathcal{F}$ », où $\mathcal{F} = \{F(\cdot\,;\theta)\,;\ \theta \in \Theta\}$ est une famille paramétrée.

Exemple : « les observations sont-elles gaussiennes ? », sans valeur des paramètres (on les estimera si on adopte H_0).

- Sous H_0, la quantité $p_j = F(a_j;\theta) - F(a_{j-1};\theta)$ dépend de θ inconnu.
- On remplace $\theta \in \Theta$ par un estimateur $\hat{\theta}_n$ et p_j par $\hat{p}_j = F(a_j;\hat{\theta}_n) - F(a_{j-1};\hat{\theta}_n)$.
- Le théorème de Pearson ne s'applique plus tel quel, mais on dispose du résultat suivant : pour k et n assez grands, et si $\hat{\theta}_n$ est l'estimateur de maximum de vraisemblance, nous avons

$$\hat{D}_n^2 = \sum_{j=1}^{k} \frac{(N_j - n\hat{p}_j)^2}{n\hat{p}_j} \quad \text{est approximativement de loi } \chi^2(k-1-d), \quad d = \dim\Theta.$$

Théorème 2.2 (test d'adéquation du χ^2 à une famille de lois)

Test de H_0 : « $F \in \mathcal{F}$ » contre H_1 : « $F \notin \mathcal{F}$ » :

$$W = \Big\{ \sum_{j=1}^{k} \frac{(n_j - n\hat{p}_j)^2}{n\hat{p}_j} > q_{\chi^2(k-1-d),\,1-\alpha} \Big\}.$$

Estimer un paramètre de dimension d enlève d degrés de liberté à la loi du χ^2.

Exemple : les niveaux de bruit sont-ils gaussiens ?

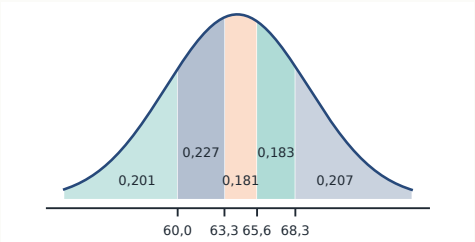
Exemple 5 (niveaux de bruit)

H_0 : « loi normale », $d = 2$, EMV $\bar{x}_n = 64{,}2$ et $s_n^2 = 25{,}2$ (bien l'EMV de σ^2, même s'il n'est pas optimal).
Histogramme à $k = 5$ classes de même effectif, 4 observations chacune, classes extrêmes prolongées jusqu'à $\pm\infty$.

Alors $\hat{p}_j = \Phi\left(\frac{a_j - \bar{x}_n}{s_n}\right) - \Phi\left(\frac{a_{j-1} - \bar{x}_n}{s_n}\right)$, soit (0,201, 0,227, 0,181, 0,183, 0,207), et

$$\hat{d}_n^2 = \sum_{j=1}^{5} \frac{(4 - 20\hat{p}_j)^2}{20\hat{p}_j} = 0{,}142.$$

Au seuil 5 %, $q_{\chi^2(2),,95} = 5{,}99$: on ne rejette pas H_0, et de loin. p-valeur : $1 - F_{\chi^2(2)}(0{,}142) = 93$ %, très élevée. On a une confiance raisonnable dans la normalité des observations.



$\mathcal{N}(64{,}2\,;\,25{,}2)$ et les 5 classes (4 observations chacune)

La loi normale ajustée et les cinq classes, avec les probabilités $\hat{p}_j$: les effectifs attendus $20\hat{p}_j$ valent de 3,6 à 4,6, un peu moins que 5 : on applique le test pour en comprendre le fonctionnement.

Le test du χ^2 est le plus connu des tests d'adéquation, mais loin d'être le meilleur : `ks.test` (Kolmogorov-Smirnov) et `shapiro.test` (Shapiro-Wilk, normalité) sont plus performants.

Bilan du chapitre 6

À retenir

- Le test du χ^2 compare des effectifs observés à des effectifs attendus ($np_j \geq 5$) ; il teste des probabilités d'événements et, en regroupant en classes, l'adéquation à une loi. Chaque paramètre estimé coûte un degré de liberté.

Situation	H_0	Statistique	Loi sous H_0
k issues, probabilités p_j données	$\mathbb{P}(\text{issue } j) = p_j$	$\sum_j (n_j - np_j)^2 / (np_j)$	$\approx \chi^2(k-1)$
Adéquation à une famille, d paramètres	$F \in \mathcal{F}$	$\sum_j (n_j - n\hat{p}_j)^2 / (n\hat{p}_j)$	$\approx \chi^2(k-1-d)$

7

chapitre

La régression linéaire

- Introduction
- Le modèle de régression linéaire simple
- Estimation par la méthode des moindres carrés

7.1

La régression linéaire

Introduction

Expliquer y par x

On observe maintenant des données bidimensionnelles : n couples (X_i, Y_i), avec X_i et Y_i non indépendants.

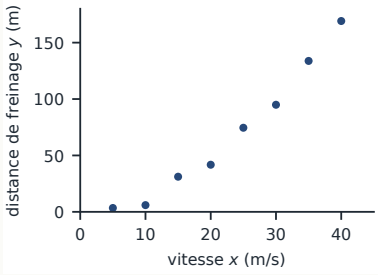
- Se pose alors la question de la dépendance entre X_i et Y_i.
- Un problème de régression consiste à chercher f telle que $Y_i \approx f(X_i)$ pour tout i.
- Le cas le plus simple est la *régression linéaire simple*, $f(x) = \beta_1 x + \beta_0$, dont les coefficients s'estiment par la méthode des moindres carrés.

Exemple 1 (distance de freinage)

On lance une voiture à une vitesse x (m/s) et l'on mesure la distance de freinage y (m), pour $n = 8$ vitesses, même véhicule et même pilote, mesures supposées indépendantes.

i	1	2	3	4	5	6	7	8
vitesse x_i	5	10	15	20	25	30	35	40
distance y_i	3,42	5,96	31,14	41,76	74,54	94,92	133,78	169,16

Quel modèle de dépendance proposer ? Une dépendance affine est-elle raisonnable ? Peut-on prévoir la distance de freinage à 50 m/s, et avec quelle précision ?



Le nuage de points (x_i, y_i) : la première chose à dessiner.

7.2

La régression linéaire

Le modèle de régression linéaire simple

Le modèle de régression

Données : n couples (x_i, y_i). On suppose que y_i est la réalisation d'une variable aléatoire Y_i, et que les x_i sont des constantes connues.

Faire une régression de y sur x, c'est étudier le type de dépendance entre y et x ; y dépend aussi d'autres facteurs, dont on suppose que les effets *s'ajoutent* à celui de x.

Définition 2.1

Le modèle de régression de Y sur x est $Y = f(x) + \varepsilon$, où Y est la *variable à expliquer*, x la *variable explicative* (prédicteur, régresseur) et ε l'*erreur* de prévision de Y par $f(x)$, ou *résidu*. Pour n observations : $Y_i = f(x_i) + \varepsilon_i$, $i \in \{1, \dots, n\}$.

Dans l'exemple, la distance de freinage dépend de la vitesse, mais aussi de l'état de la route, de la météo, du conducteur : la vitesse est contrôlée par le conducteur, donc constante connue, mais même à x connu, y n'est pas prévisible avec certitude. Il reste à préciser la forme de f et la loi des résidus.

Définition 2.2

Un modèle de régression linéaire simple est :

$$\forall i \in \{1, \dots, n\}, \qquad Y_i = \beta_1 x_i + \beta_0 + \varepsilon_i,$$

où $\beta_0, \beta_1 \in \mathbb{R}$ sont inconnus et les résidus ε_i sont indépendants, de même loi, centrés ($\mathbb{E}(\varepsilon_i) = 0$) et de variance σ^2.

Ce que l'on veut faire, et ce que « linéaire » veut dire

Le modèle suppose des mesures indépendantes, faites dans les mêmes conditions, et des effets des autres facteurs qui s'équilibrent ($\mathbb{E}(\varepsilon_i) = 0$). Alors

$$\mathbb{E}(Y_i) = \beta_1 x_i + \beta_0 \text{ et } \mathrm{Var}(Y_i) = \sigma^2$$

Donc, σ^2 mesure le *bruit*, le poids des facteurs autres que x. Si $\sigma^2 = 0$, les points sont alignés et Y_i n'est plus aléatoire.

Les problèmes statistiques

- estimer β_1, β_0 et σ^2, ponctuellement et par intervalle de confiance ;
- construire des tests d'hypothèses sur β_1, β_0 et σ^2 ;
- prévoir y connaissant x ;
- valider le modèle : la liaison est-elle bien affine ?

On va se limiter à l'estimation (sans préciser la loi des résidus).

Important : linéaire en les paramètres

La liaison entre x et y n'est pas forcément *affine* : ce qui compte, c'est que y dépende linéairement du couple (β_1, β_0).
Sont donc linéaires :

1. $Y_i = \beta_1 \ln x_i + \beta_0 + \varepsilon_i$;
2. $Y_i = \beta_2 x_i^2 + \beta_1 x_i + \beta_0 + \varepsilon_i$;
3. Cobb-Douglas, $Y_i = \beta_0 x_i^{\beta_1} \varepsilon_i$:
   $\ln Y_i = \beta_1 \ln x_i + \ln \beta_0 + \ln \varepsilon_i$;
4. logistique, $Y_i = \frac{e^{u_i}}{1+e^{u_i}}$ avec $u_i = \beta_1 x_i + \beta_0 + \varepsilon_i$:
   $\ln \frac{Y_i}{1-Y_i} = u_i$.

En revanche $Y_i = \beta_1 + e^{\beta_0 x_i} + \varepsilon_i$ n'est pas linéaire.

7.3

La régression linéaire

Estimation par la méthode des moindres carrés

Le nuage de points et les indicateurs empiriques

Notations

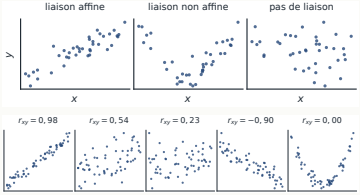
$$\bar{x}_n = \frac{1}{n}\sum_i x_i, \qquad s_x^2 = \frac{1}{n}\sum_i (x_i - \bar{x}_n)^2 = \frac{1}{n}\sum_i x_i^2 - \bar{x}_n^2, \qquad c_{xy} = \frac{1}{n}\sum_i (x_i - \bar{x}_n)(y_i - \bar{y}_n),$$

$$\bar{y}_n = \frac{1}{n}\sum_i y_i, \qquad s_y^2 = \frac{1}{n}\sum_i (y_i - \bar{y}_n)^2, \qquad r_{xy} = \frac{c_{xy}}{s_x s_y},$$

covariance et coefficient de corrélation linéaire empiriques. $\bar{x}_n$, s_x^2 sont des constantes ; $\bar{y}_n$, s_y^2, c_{xy}, r_{xy} sont des réalisations de $\bar{Y}_n$, S_Y^2, C_{xY}, R_{xY}.

La première chose à faire est de dessiner le nuage des points (x_i, y_i) pour déterminer le type de liaison. Sur l'exemple du freinage, la liaison affine peut être retenue à première vue ; on verra plus loin des critères statistiques plus précis.

Propriétés de r_{xy} : $r_{xy} \in [-1, 1]$; $r_{xy} = \pm 1$ si et seulement si les points sont alignés (pente positive, resp. négative) ; sans dépendance, $r_{xy} \approx 0$. Réciproquement, $r_{xy} \approx 0$ exclut une dépendance affine, pas une dépendance non affine.



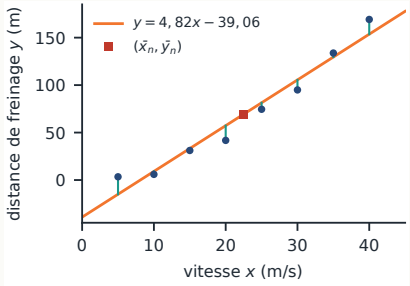
Trois types de liaison, puis r_{xy} sur cinq nuages : proche de 0 sans liaison affine, *y compris* avec une liaison non affine (dernier nuage).

La droite des moindres carrés

On cherche la droite « la plus proche » du nuage : la méthode des moindres carrés minimise la somme des carrés des distances *verticales* des points à la droite $y = \beta_1 x + \beta_0$ (et non la distance euclidienne), ou de façon équivalente l'*erreur quadratique moyenne*

$$\delta^2(\beta_0, \beta_1) = \frac{1}{n}\sum_{i=1}^{n}(y_i - \beta_1 x_i - \beta_0)^2 = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2.$$

Annuler les dérivées partielles : $\partial_{\beta_0}\delta^2 = -\frac{2}{n}\sum_i(y_i - \beta_1 x_i - \beta_0) = 0$ donne $\bar{y}_n - \beta_1 \bar{x}_n - \beta_0 = 0$: la droite passe par le barycentre $(\bar{x}_n, \bar{y}_n)$ du nuage. Puis $\partial_{\beta_1}\delta^2 = -\frac{2}{n}\sum_i x_i(y_i - \beta_1 x_i - \beta_0) = 0$ donne, avec la première, $c_{xy} - \beta_1 s_x^2 = 0$.



La droite des moindres carrés sur l'exemple, les résidus verticaux $y_i - \hat{y}_i$ (vert) et le barycentre du nuage.

Théorème 3.1 (estimateurs des moindres carrés)

$$\hat{\beta}_1 = \frac{c_{xy}}{s_x^2}, \qquad \hat{\beta}_0 = \bar{y}_n - \frac{c_{xy}}{s_x^2}\bar{x}_n, \qquad \text{droite des moindres carrés : } y = \hat{\beta}_1 x + \hat{\beta}_0 = \bar{y}_n + \frac{c_{xy}}{s_x^2}(x - \bar{x}_n).$$

L'erreur minimale et la qualité des estimateurs

L'erreur quadratique moyenne minimale est

$$\delta^2_{\min} = \frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat\beta_1 x_i - \hat\beta_0\right)^2 = s_y^2 - 2\frac{c_{xy}^2}{s_x^2} + \frac{c_{xy}^2}{s_x^4}s_x^2 = s_y^2 - \frac{c_{xy}^2}{s_x^2} = s_y^2\,(1 - r_{xy}^2).$$

D'où $r_{xy}^2 \leq 1$, avec $\delta^2_{\min} = 0$ si et seulement si $r_{xy} = \pm 1$, c'est-à-dire si les points sont alignés. (C'est ce résultat qui sert à estimer graphiquement des paramètres sur un graphe de probabilités.)

Il reste à montrer que $\hat\beta_1$ et $\hat\beta_0$ sont de bons estimateurs de β_1 et β_0 dans le modèle linéaire simple. Ce sont en fait les meilleurs estimateurs linéaires possibles.

Théorème 3.2
$\hat\beta_1$ et $\hat\beta_0$ sont des estimateurs sans biais de β_1 et β_0.

Preuve. Comme $\sum_i (x_i - \bar x_n) = 0$,

$$\hat\beta_1 = \frac{1}{ns_x^2}\sum_i (x_i - \bar x_n)(Y_i - \bar Y_n) = \frac{1}{ns_x^2}\sum_i (x_i - \bar x_n)Y_i, \qquad \mathbb{E}(\hat\beta_1) = \frac{1}{ns_x^2}\sum_i (x_i - \bar x_n)(\beta_1 x_i + \beta_0) = \frac{\beta_1}{s_x^2}\Big(\frac{1}{n}\sum_i x_i^2 - \bar x_n^2\Big) = \beta_1.$$

Puis $\mathbb{E}(\hat\beta_0) = \mathbb{E}(\bar Y_n) - \beta_1 \bar x_n = \frac{1}{n}\sum_i(\beta_1 x_i + \beta_0) - \beta_1 \bar x_n = \beta_0$. ■

Variances et théorème de Gauss-Markov

Théorème 3.3

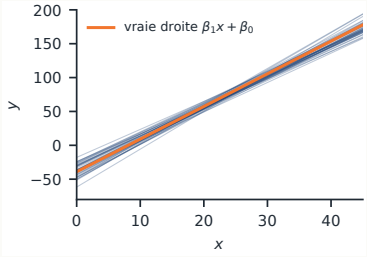
$$\mathrm{Var}(\hat{\beta}_1) = \frac{\sigma^2}{n s_x^2}, \qquad \mathrm{Var}(\hat{\beta}_0) = \frac{\sigma^2}{n}\left(1 + \frac{\bar{x}_n^2}{s_x^2}\right),$$

$$\mathrm{Cov}(\hat{\beta}_1, \hat{\beta}_0) = -\frac{\sigma^2 \bar{x}_n}{n s_x^2}, \qquad \mathrm{Cov}(\hat{\beta}_1, \bar{Y}_n) = 0.$$

Estimateurs convergents en moyenne quadratique et asymptotiquement non corrélés. Plus s_x^2 est grand (des x_i bien étalés), mieux la pente est estimée.

Théorème 3.4 (théorème de Gauss-Markov)

$\hat{\beta}_1$ et $\hat{\beta}_0$ sont les estimateurs sans biais et de variance minimale (ESBVM) de β_1 et β_0 parmi tous les estimateurs sans biais *linéaires*, c'est-à-dire combinaisons linéaires des Y_i.



40 jeux de données simulés suivant le modèle de l'exemple ($\beta_1 = 4{,}82$, $\beta_0 = -39{,}06$, $\sigma^2 = 168{,}4$) et leurs droites des moindres carrés : $\hat{\beta}_1$ et $\hat{\beta}_0$ sont des variables aléatoires, centrées sur les vraies valeurs.

Toutes les propriétés de cette section sont valables quelle que soit la loi des résidus ε_i.

Estimation de la variance des résidus

Puisque $\sigma^2 = \mathrm{Var}(\varepsilon_i) = \mathrm{Var}(Y_i - \beta_1 x_i - \beta_0)$, il est naturel d'estimer σ^2 par la variance empirique des $Y_i - \hat{\beta}_1 x_i - \hat{\beta}_0$.

Définition 3.1 (résidus empiriques, variance résiduelle)

Les $E_i = Y_i - \hat{Y}_i = Y_i - \hat{\beta}_1 x_i - \hat{\beta}_0$ sont les résidus empiriques. Leur variance empirique $S^2_{Y|x}$ est la variance résiduelle.

Les résidus empiriques étant centrés, $S^2_{Y|x} = \frac{1}{n}\sum_{i=1}^n E_i^2 = \delta^2_{\min} = S_Y^2\,(1 - R^2_{xY})$: la variance résiduelle n'est autre que l'erreur quadratique moyenne minimale.

Comme la variance empirique d'un échantillon, elle est biaisée ; ici il y a deux paramètres estimés, et l'on multiplie par $\frac{n}{n-2}$ pour la débiaiser.

Théorème 3.5

$$\hat{\sigma}^2 = \frac{n}{n-2} S^2_{Y|x} = \frac{n}{n-2} S_Y^2\,(1 - R^2_{xY}) = \frac{1}{n-2}\sum_{i=1}^n \left(Y_i - \hat{\beta}_1 x_i - \hat{\beta}_0\right)^2$$ est un estimateur sans biais de σ^2.

On n'a pas de résultat sur la variance de cet estimateur dans le cas général.

Retour à la distance de freinage

Exemple 1 (suite)

Les indicateurs statistiques sont

$$\bar{x}_n = 22{,}5, \qquad \bar{y}_n = 69{,}33, \qquad s_x^2 = 131{,}25,$$

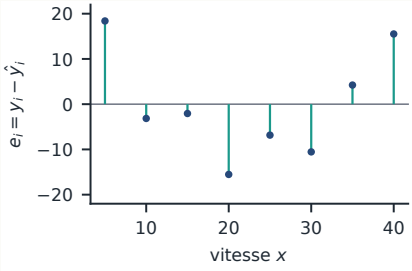
$$s_y^2 = 3172{,}54, \qquad c_{xy} = 632{,}31, \qquad r_{xy} = {,}9799.$$

Le fait que r_{xy} soit très proche de 1 indique une forte corrélation linéaire positive, visible sur le nuage. Les estimations des paramètres sont

$$\hat{\beta}_1 = \frac{c_{xy}}{s_x^2} = 4{,}82, \qquad \hat{\beta}_0 = \bar{y}_n - \hat{\beta}_1 \bar{x}_n = -39{,}06,$$

$$\hat{\sigma}^2 = \frac{n}{n-2} s_y^2 (1 - r_{xy}^2) = 168{,}4.$$

La droite des moindres carrés a pour équation $y = 4{,}82x - 39{,}06$ (`abline` en R la superpose au nuage). Prévision à 50 m/s : $4{,}82 \times 50 - 39{,}06 = 201{,}9$ m.



Résidus empiriques $e_i = y_i - \hat{y}_i$ de la droite : ils ont une structure (positifs aux extrémités, négatifs au milieu), signe qu'une droite n'est pas le meilleur modèle.

Bilan du chapitre 7

À retenir

- **Modèle linéaire simple** : $Y_i = \beta_1 x_i + \beta_0 + \varepsilon_i$, résidus iid centrés de variance σ^2 ; « linéaire » signifie linéaire en les paramètres.
- **Moindres carrés** : $\hat{\beta}_1 = c_{xy}/s_x^2$, $\hat{\beta}_0 = \bar{y}_n - \hat{\beta}_1 \bar{x}_n$; la droite passe par le barycentre, l'erreur minimale est $s_y^2(1 - r_{xy}^2)$, et $\hat{\sigma}^2 = \frac{n}{n-2} s_y^2(1 - r_{xy}^2)$ est sans biais. Estimateurs sans biais et de variance minimale parmi les linéaires (Gauss-Markov), quelle que soit la loi des résidus.

Une seule idée pour les chapitres 4 à 6 : une fonction pivotale de loi connue, dont on lit les quantiles pour encadrer un paramètre (chapitre 4) ou décider d'une hypothèse (chapitres 5 et 6).

Références

- J. Mathieu, *Probabilités et Principes et méthodes statistiques*, polycopié CPES. (Partie II, chapitres 4 à 7 : le support de ces diapositives, avec les tables des lois usuelles en annexe C.)
- G. Saporta, *Probabilités, analyse des données et statistique*, Technip, 3e éd., 2011. (Référence générale en français.)
- D. C. Montgomery, G. C. Runger, *Applied Statistics and Probability for Engineers*, Wiley. (Exemples du carburant de fusée et des essais thérapeutiques.)
- Les commandes R correspondant à chaque test (`t.test`, `binom.test`, `chisq.test`, `lm`) sont décrites dans le polycopié et dans l'annexe D.

Questions : `dario.prandi@centralesupelec.fr`